

Estratégia de Modelagem Preditiva

Abordagem escolhida: Regressão

Optamos por um modelo de regressão. A análise exploratória evidenciou relações aproximadamente lineares entre o nps e as principais variáveis operacionais, especialmente o número de dias de atraso ($r = -0.6$) e número de reclamações ($r = -0.5$). Esse comportamento favorece modelos que exploram relações lineares como ponto de partida. Além disso, um modelo de regressão preserva a informação contínua do NPS. A classificação interrompe essa informação, um cliente com nota 1 e nota 6 seriam ambos rotulados como Detrator, embora seu grau de insatisfação seja muito distinto. Por último, prever o valor da nota nos permite fazer a classificação da categoria do NPS a partir da nota prevista ($\leq 6 \rightarrow$ Detrator, $7-8 \rightarrow$ Neutro, $\geq 9 \rightarrow$ Promotor). O modelo cobre as duas necessidades.

Variável Alvo

nps_score: Nota de satisfação atribuída pelo próprio cliente ao final da jornada de compra, em uma escala de 0 a 10.

- Coletada após o encerramento da experiência (pós-entrega e pós-atendimento)
- Representa a percepção declarada do cliente, sem intermediação da empresa
- A partir da nota prevista, a classificação é derivada com a seguinte regra de mercado:
 - Detrator: $NPS \leq 6$
 - Neutro: $7 \leq NPS \leq 8$
 - Promotor: $NPS \geq 9$

Variáveis de Entrada (Features)

As variáveis abaixo estão disponíveis antes da coleta do NPS e, portanto, não introduzem vazamento temporal.

Variáveis com associação identificada na EDA

Variável	Grupo	Correlação com NPS	Observação
delivery_delay_days	Logística	-0,60	Principal driver de insatisfação; relação linear clara
complaints_count	Atendimento	-0,50	Segundo maior sinal; relação linear com NPS

Variável	Grupo	Correlação com NPS	Observação
customer_service_contacts	Atendimento	-0,35	Atenção: correlação de 0,75 com complaints_count (multicolinearidade)
resolution_time_days	Atendimento	-0,19	Sinal fraco, mas relevante no contexto de atraso + atendimento lento

Nota sobre multicolinearidade: complaints_count e customer_service_contacts são altamente correlacionadas entre si ($r = 0,75$). Em modelos lineares, recomenda-se manter apenas a variável com maior poder preditivo individual (complaints_count).

Variáveis sem associação direta identificada

Mesmo sem associação bivariada clara com o NPS, estas variáveis podem contribuir no contexto multivariado ou em modelos não-lineares:

Variável	Grupo
delivery_time_days	Logística
freight_value / freight_rate	Logística
delivery_attempts	Logística
order_value	Pedido
items_quantity	Pedido
discount_value / pct_desconto	Pedido
payment_installments	Pedido
customer_age	Perfil
customer_region	Perfil
customer_tenure_months	Perfil

Variáveis Excluídas por risco de Data Leakage

Variável	Motivo da exclusão
repeat_purchase_30d	Evento posterior à pesquisa de NPS. A EDA mostrou que 92,2% dos promotores efetuaram recompra em 30 dias e 0% dos detratores. Usar essa variável como feature vazaria diretamente o resultado que o modelo tenta prever.
csat_internal_score	Apresenta correlação de 0,56 com NPS, mas o momento de cálculo é desconhecido. Caso seja calculado com base no próprio NPS ou após a pesquisa, representa leakage. Sem clareza sobre a metodologia interna, optamos por não incluí-la.
classificacao	Variável derivada diretamente do nps_score (Detrator/Neutro/Promotor). Incluí-la seria leakage, pois ela é basicamente a target com outro nome.

Algoritmos Candidatos

A estratégia é partir de um baseline interpretável e evoluir para modelos mais complexos apenas se o ganho de performance justificar a perda de interpretabilidade.

Algoritmo	Papel
Regressão Linear (OLS)	Baseline
Ridge / Lasso	Baseline regularizado
Random Forest Regressor	Modelo não-linear
Gradient Boosting (XGBoost / LightGBM)	Modelo não-linear

Métricas de Avaliação

Regressão

Métrica	Descrição	Quando usar
RMSE	Raiz do erro quadrático médio	Penaliza erros grandes; útil quando prever um detrator como promotor é muito custoso
MAE	Erro absoluto médio	Mais intuitivo para o negócio ("em média o modelo erra X pontos de NPS")
R ²	Proporção da variância	Referência geral de qualidade do ajuste

Classificação derivada

Métrica	O que mede
Accuracy	Proporção de classificações corretas
F1-score	Equilíbrio entre precisão e recall para cada segmento (Detrator / Neutro / Promotor)
Matriz de confusão	Onde o modelo erra (ex.: neutros classificados como detratores)

Prioridade de negócio: a métrica mais importante é o recall na classe Detrator, o custo de não identificar um detrator (falso negativo) é maior do que o custo de acionar preventivamente um cliente que seria neutro (falso positivo).